

SPRAWOZDANIE

Zajęcia: Eksploracja i wizualizacja danych
Prowadzący: prof. dr hab. Vasyl Martsenyuk

Laboratorium 2

12.11.2021

Temat: Graficzna wizualizacja danych z użyciem bibliotek „matplotlib” i „seaborn”

Szymon Żoczek
Informatyka II stopień,
niestacjonarne (zaoczne),
II1 semestr,
<https://github.com/Szoczek/eiwd.git>

Na podstawie danych ze zbioru [2] lub danych losowych, wygenerować wykresy analogiczne do przedstawionych na zajęciach.

1. Wygenerować wykres liniowy

```
In [1]: # załadowanie bibliotek

import matplotlib.pyplot as plt
%matplotlib inline

import numpy as np

import pandas as pd
```

```
In [2]: # załadowanie danych
import os


path = r"E:\studiaMGR\SEMESTR III\EiWD\2\IHME_GDP_1960_2050_CSV_1\IHME_GDP_1960_2050_Y2021M09D22.CSV"
folder = r"E:\studiaMGR\SEMESTR III\EiWD\2\wykresy"

data = pd.read_csv(path, low_memory=False)
data.head()
```

```
In [4]: # wykres liniowy

years = data['year'][:5_000]

plt.rcParams["figure.figsize"] = (20,10)
plt.plot(years)
plt.savefig(os.path.join(folder, 'wykres1.svg'), dpi=400, bbox_inches='tight')
```



2. Wygenerować kilka wykresów obok siebie




In [5]: *# kilka podwykresów*

```
fig = plt.figure()
ax0 = fig.add_subplot(2,2,1)
ax1 = fig.add_subplot(2,2,2)
ax2 = fig.add_subplot(2,2,3)

gdp_ppp_mean = data['gdp_ppp_mean'][:,1_000]
gdp_ppp_lower = data['gdp_ppp_lower'][:,1_000]

ax0.plot(years)
ax1.plot(gdp_ppp_mean)
ax2.plot(gdp_ppp_lower)


plt.savefig(os.path.join(folder, 'wykres2.svg'), dpi=400, bbox_inches='tight')
```



3. Wygenerować wykres liniowy i zdefiniować jego formatowanie

In [6]: *# wykres punktowy ze zdefiniowanymi kolorami, stylem znaczników i linii*

```
from numpy.random import randn
plt.plot(randn(30).cumsum(), 'go-')
plt.savefig(os.path.join(folder, 'wykres3.svg'), dpi=400, bbox_inches='tight')
```



4. Wygenerować z dodanym wykresem interpolacji liniowej i legendą


```
In [7]: # wykres interpolacji liniowej

data = np.random.randn(30).cumsum()
plt.plot(data, 'k--', label='Etykieta')
plt.plot(data, 'r-', label="steps-post", drawstyle="steps-post")
plt.legend(loc='best')

# normalizacja
# years_normal = years.div(years.sum())
# elim_ch_normal = elim_ch.div(elim_ch.sum())
# prelim_est_normal = prelim_est.div(prelim_est.sum())

# plt.plot(years_normal, 'k--', label='years', drawstyle='steps-pre')
# plt.plot(elim_ch_normal, 'g.', label='elim ch', drawstyle='steps-mid')
# plt.plot(prelim_est_normal, 'r-', label='elim ch', drawstyle='steps-post')
# plt.legend(loc='best')

plt.savefig(os.path.join(folder, 'wykres5.png'), dpi=400, bbox_inches='tight')
```



5. Wygenerować wykres liniowy i dodać do niego samodzielnie zdefiniowane etykiety osi

```
In [9]: # dodanie etykiet na osi

fig = plt.figure()
ax = fig.add_subplot(1,1,1)
ax.plot(np.random.randn(1000).cumsum())


ax.set_xticks([0, 250, 500, 750, 1000])
ax.set_yticks([-50, -25, 0, 25, 50])

ax.set_xticklabels(['one', 'two', 'three', 'four', 'five'], rotation=90, fontsize='small')

# dodanie właściwości wykresu słownikiem

props = {
    'title': "Tytuł",
    'xlabel': "Kroki",
    'ylabel': "Wartości"
}
ax.set(**props)


plt.savefig(os.path.join(folder, 'wykres6.svg'), dpi=400, bbox_inches='tight')
```



6. Wygenerować kilka wykresów liniowych w różnych kolorach i nałożyć je na siebie

```
In [10]: fig = plt.figure();
ax = fig.add_subplot(1,1,1)
ax.plot(randn(1000).cumsum(), 'k', label='one')
ax.plot(randn(1000).cumsum(), 'r--', label='two')
ax.plot(randn(1000).cumsum(), 'g.', label='three')
ax.legend(loc='best')

plt.savefig(os.path.join(folder, 'wykres7.svg'), dpi=400, bbox_inches='tight')
```



7. Zapisać wygenerowany wykres do pliku

In [15]: *# zapis wykresu do pliku*

```
path = r"E:\studiaMGR\SEMESTR III\EiWD\2\wykresywykres01.svg"
plt.savefig(path, dpi=400, bbox_inches='tight')
```


<Figure size 1440x720 with 0 Axes>

8. Wygenerować wykres liniowy z użyciem indeksu


```
In [21]: import numpy as np
import pandas as pd

xmax = 3_000

s = pd.Series(years, index=np.arange(0, xmax*5_000, 5_000))
s.plot(kind='line', logy=False, xticks=[0, xmax/8, xmax/4, xmax/2, xmax], xlim=[0, xmax], grid=True, style='r--')
plt.savefig(os.path.join(folder, 'wykres8.svg'), dpi=400, bbox_inches='tight')
```



```
In [22]: s = pd.Series(np.random.randn(10).cumsum(), index=np.arange(0, 100, 10))
s.plot(kind='line', logy=False, xticks=[1, 2, 4, 8, 16, 32, 64, 128], xlim=[0, 100], grid=True, style='r--')
plt.savefig(os.path.join(folder, 'wykres8.svg'), dpi=400, bbox_inches='tight')
```




9. Wygenerować kilka wykresów liniowych ułożonych jeden pod drugim

```
In [23]: df = pd.DataFrame(np.random.randn(10, 6).cumsum(0), columns=['A', 'B', 'C', 'D', 'E', 'F'], index=np.arange(0, 100, 10))
df.plot(subplots=True, sharex=True, sharey=True, title='Tytuł wykresu', sort_columns=True)

#df = num_data
#df.plot(subplots=True, sharex=True, sharey=True, title='Wykresy wartości liczbowych', sort_columns=True)

plt.savefig(os.path.join(folder, 'wykres9.png'), dpi=400, bbox_inches='tight')
```




10. Wygenerować wykresy słupkowe ułożone poziomo i pionowo

```
In [26]: #data = pd.Series(np.random.rand(16), index=list('abcdefghijklmnop'))
data = pd.DataFrame(num_data[['location_id', 'gdp_ppp_mean']][:10], columns=['gdp_ppp_mean', 'location_id'])

fig, axes = plt.subplots(2, 1)

data.plot.bar(ax = axes[0], color='k', alpha=0.7)
data.plot.barh(ax = axes[1], color='r', alpha=0.7)

plt.savefig(os.path.join(folder, 'wykres10.png'), dpi=400, bbox_inches='tight')
```




11. Wygenerować wykres słupkowy z pogrupowanymi danymi

```
In [27]: data = np.random.rand(3, 5)

df = pd.DataFrame(data, index=['a', 'b', 'c'], columns=pd.Index(['1', '2', '3', '4', '5'], name='Nazwa'))
df.plot.bar()


plt.savefig(os.path.join(folder, 'wykres11.png'), dpi=400, bbox_inches='tight')
```



12. Wygenerować wykres słupkowy skumulowany

```
In [28]: df.plot.bar(stacked=True, alpha=0.8)

plt.savefig(os.path.join(folder, 'wykres12.png'), dpi=400, bbox_inches='tight')
```




13. Wygenerować wykres słupkowy przy użyciu biblioteki seaborn

```
In [37]: #sns.barplot(x='tip_pct', y='day', data=tips, orient='h', hue='sex')
import seaborn as sns

max = 100_000
per = 1_000
sns.barplot(y=num_data.gdp_ppp_mean[:max:per], x = num_data.year[:max:per])


plt.savefig(os.path.join(folder, 'wykres14.png'), dpi=400, bbox_inches='tight')
```



14. Wygenerować histogram

```
In [38]: # histogram
#tips['tip_pct'].plot.hist(bins=50)
num_data['year'].plot.hist(bins=10, color='red')

plt.savefig(os.path.join(folder, 'wykres15.png'), dpi=400, bbox_inches='tight')
```

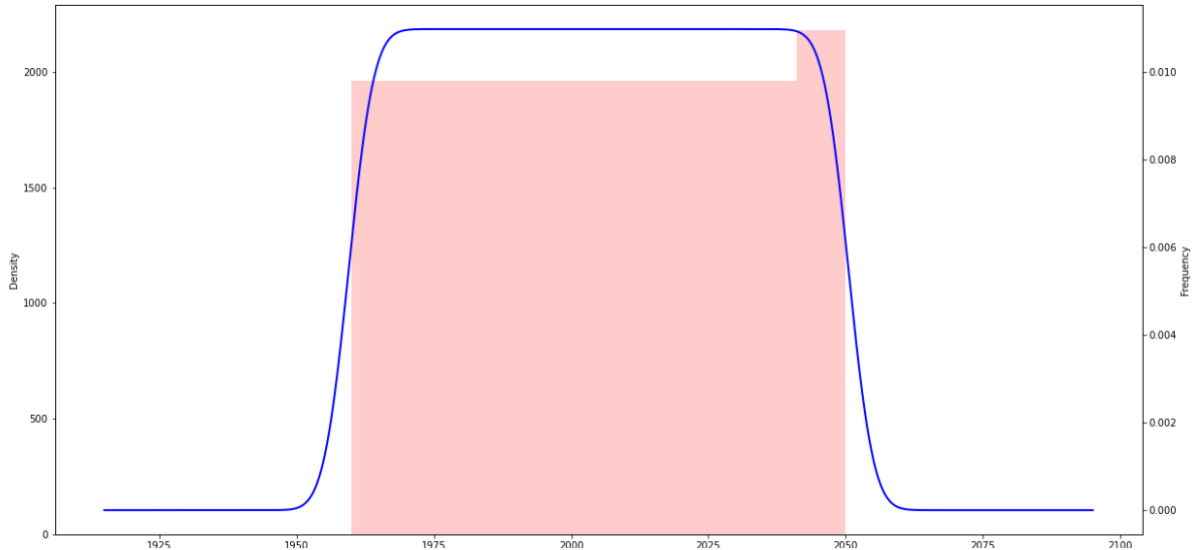


15. Wygenerować wykres gęstości prawdopodobieństwa i nałożyć go na histogram

In [39]: # wykres gęstości

```
#tips['tip_pct'].plot.kde()
num_data['year'].plot.hist(bins=10, color='red', alpha=0.2)
ax = num_data['year'].plot.kde(color='blue', linewidth=2.0, secondary_y=True)
ax.set_ylabel("Frequency", fontsize=10)

plt.savefig(os.path.join(folder, 'wykres16.png'), dpi=400, bbox_inches='tight')
```




16. Wygenerować wykres regresji liniowej

In [41]: # wykres regresji liniowej

```
# losowe dane
n = 1_000
data = pd.DataFrame({
    'x': np.random.rand(n)*5-2,
    'y': np.random.rand(n)*2+5,
    'z': np.random.rand(n)
})
# różnica logarytmów
data = np.log(data).diff()

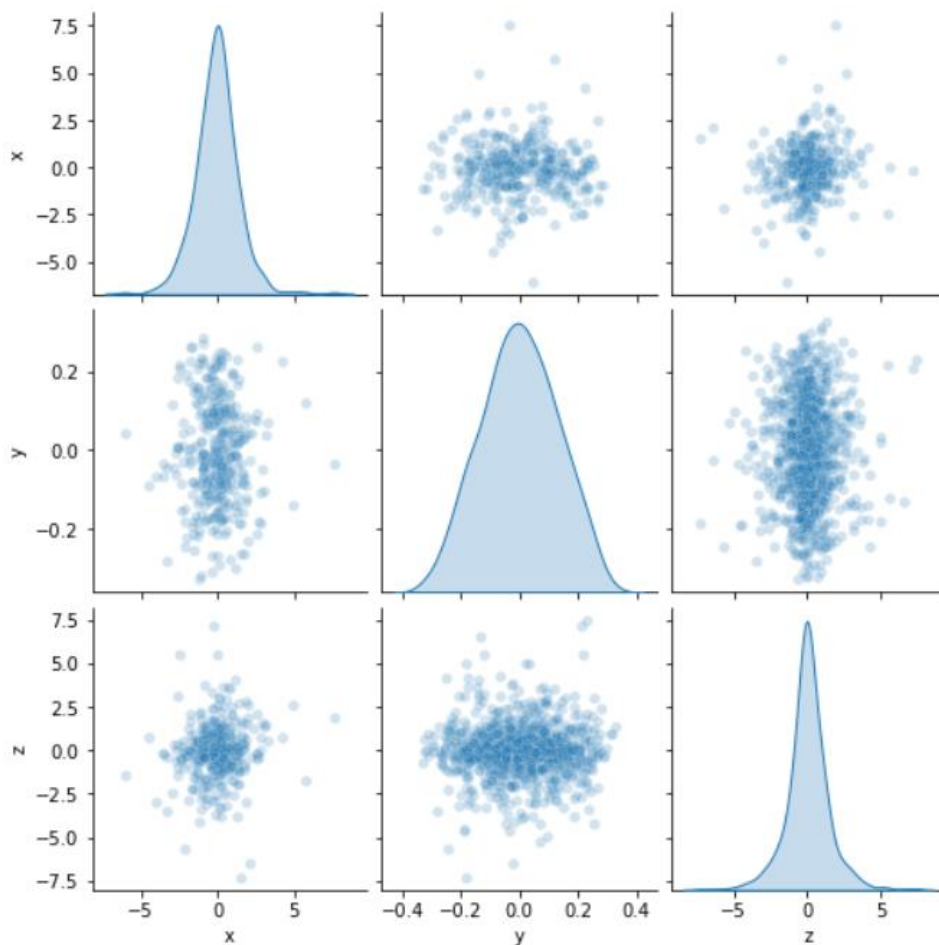
sns.regplot(x='x', y='y', data=data)
plt.title('Zależność  $\log\{x\}$  od  $\log\{y\}$ ')
```



17. Wygenerować wszystkie możliwe wykresy rozrzutu oraz wykresy gęstości

```
# wszystkie wykresy rozrzutu
```

```
#sns.pairplot(trans_data, diag_kind='kde', plot_kws={'alpha': 0.2})
sns.pairplot(data, diag_kind='kde', plot_kws={'alpha': 0.2})
```



18. Wygenerować wykres pudełkowy

```
import math

data['year'] = data.year.apply(lambda x: 0 if x=='-' else math.log(abs(int(x)+1),10))

sns.catplot(x='location_name', y='year', kind='box', data=data)
```

